

电动汽车消费者转型分析

TeamB DATA2600409

2026年7月31日

摘要

本道题目数据集为 50,000 条有关电动汽车的消费者记录，三个子任务分别为对电动汽车采用意愿、家庭充电安装条件和里程焦虑敏感人群的估计和识别。

本题难点在于数据庞大，除开数据条数较多外，二十多列数据维度也为数据分析任务提出了挑战。在数据预处理阶段，本文识别出部分维度存在缺失，在补足后又进行了缩尾和对数变换以提升数据质量。最终得到了一个 34 乘以 50,000 的数据集。在模型选择上，考虑到数据集中有较多的分类变量，而分析任务均为归类识别，本文采取了 CatBoost 模型而非 LightBGM 或 XGBoost 模型。

在子任务一中，本文额外添加了 8 个交互特征，并使用 CatBoost 模型在测试集中得到了 86.33% 的准确率。在子任务二中，本文尝试了包括原始特征（赛题推荐特征）、诊断上界、跨任务堆叠三层级对照设计，甚至是随机森林算法均无法突破 0.65 左右的准确率。通过 EDV，本文认为，预测效果较差主要是由于原始数据中特征变量区分度较低。在子任务三中，由于题目要求以 5 为边界将答案二值化，而大量分布在 5 附近的数据特征分布高度重叠，要在这个区间做好预测，需要通过 EDV 构造出精细的交互特征变量，以及本文特别引入了主方案-消融方案对照模型，并尤其注重位于 5 附近的边界样本分析，以探究模型对集中分布于中间的边界样本的预测水平。最终，本文给出并实现了一套统一的 CatBoost 建模框架、跨任务无泄漏的堆叠设计。而任务二的失败则是一个从 EDV 到负结果报告的反面教材。

本文所有代码和中间文件均在 <https://github.com/blackwhitetony/innoCupTaskB> 仓库中开源。

关键词：CatBoost 电动汽车分类预测 EDV

目录

1	问题背景与重述	1
1.1	赛题背景	1
1.2	三个子问题	1
1.3	总体技术路线	1
2	数据探索与预处理	2
2.1	数据概况	2
2.2	数据清洗流水线	2
2.3	最终数据规格	3
3	子问题一：电动汽车采用意愿分类	3
3.1	问题定义与难点	3
3.2	探索性数据分析	3
3.2.1	目标变量分布	3
3.2.2	年收入与采用意愿的关系	4
3.2.3	核心特征相关性分析	4
3.3	特征工程	5
3.4	训练策略与超参数	6
3.5	实验结果	6
3.5.1	验证集方案对比	6
3.5.2	类别权重消融	7
3.5.3	混淆矩阵分析	7
3.5.4	特征重要性排名	8
4	子问题二：家庭充电设施安装潜力预测	8
4.1	问题定义与难点	8
4.2	探索性数据分析	9
4.2.1	目标变量分布	9
4.2.2	充电站距离与家充状态	9
4.2.3	城市类型与家充状态	9
4.3	EDV预诊断：特征来源信号验证	10
4.4	S0/S1/S2三方案对照设计	11
4.5	特征工程	11
4.6	实验结果：负结果报告	12
4.6.1	S1诊断上界	12
4.6.2	S2 OOF概率堆叠	12
4.7	原因分析与方法论贡献	12
4.7.1	不可观测因素分析	12

4.7.2	方法论贡献	13
5	子问题三：里程焦虑敏感度识别	13
5.1	问题定义与难点	13
5.2	探索性数据分析	13
5.2.1	目标分布与评分分布	13
5.2.2	充电困难度与EV知识按焦虑分组	14
5.2.3	核心特征相关性	14
5.3	特征工程	15
5.4	Main与Ablation消融设计	16
5.5	实验结果	16
5.5.1	交叉验证阶段	16
5.5.2	验证集方案对比	16
5.5.3	Main vs Ablation 因果分析	17
5.5.4	混淆矩阵	17
5.5.5	特征重要性排名	17
5.5.6	边界样本分析	18
5.6	跨任务特征比较	19
6	综合讨论	19
6.1	三任务横向对比	19
6.2	CatBoost统一技术栈的优势	20
6.3	特征工程策略反思	20
6.4	任务二负结果的学术价值	20
7	结论与展望	21
7.1	主要发现	21
7.2	方法学贡献	21
7.3	局限性	22
A	源代码文件清单	23
B	运行环境	24
C	开源代码仓库	24
D	模型调用方式	24

1 问题背景与重述

1.1 赛题背景

电动汽车正在重塑交通的未来。消费者从燃油车转向电动车的决策涉及人口特征、通勤模式、充电设施可及性、环保态度、技术接受度与财务状况等多项因素，单一维度的分析难以给出完整刻画。《电动汽车革命：消费者行为与充电洞察》数据集收录50,000条消费者记录，覆盖上述各维度，为消费者转型决策建模提供较为全面的信息基础。

1.2 三个子问题

赛题的核心是三个分类任务。它们的预测目标、任务类型和评分权重汇总在表1.1中。

表 1.1: 赛题子问题概览

子问题	预测目标	类型	权重
任务一：采用意愿分类	ev_adoption_likelihood (Low/Medium/High)	三分类	20%
任务二：家充安装潜力预测	home_charging_available (0/1)	二分类	40%
任务三：里程焦虑敏感度识别	range_anxiety_score $\rightarrow$ binary ($\geq 5=1, <5=0$)	二分类	40%

最终成绩由三项准确率加权求和得出：

$$\text{Score} = \text{ACC}_1 \times 100 \times 0.2 + \text{ACC}_2 \times 100 \times 0.4 + \text{ACC}_3 \times 100 \times 0.4 \quad (1.1)$$

三项子问题中，任务二与任务三合计占评分权重80%。因此，建模资源分配需向这两项倾斜，不宜在三者之间平均分配。

1.3 总体技术路线

为保证结果可复现且不同方案之间具备可比性，三项任务共用一套实验框架：

- 使用固定随机种子2026，按目标变量进行分层抽样，划分80%训练集和20%独立验证集；
- 仅在训练集内部执行5折分层交叉验证，用于模型选择和超参数优化；
- 所有数据变换（缺失值填补、缩尾边界、编码器）仅从训练折计算，禁止利用验证集统计量；
- 每项任务先训练逻辑回归作为可解释性基线，再训练CatBoost作为非线性主模型；
- 模型确定后，在独立验证集上仅评估一次，不再反复调整。

本研究统一采用CatBoost[1]作为各项任务的主模型。CatBoost原生支持分类特征，city_type、education_level等变量可直接输入，无需独热编码转换，简化数据预处理流程。内置的Ordered Boosting与Ordered Target Encoding机制有助于抑制预测偏移；数值缺失值的自动处理也与本研究预处理策略一致。对称树结构参数规模较小，对过拟合具备一定抵抗力。

2 数据探索与预处理

2.1 数据概况

原始数据集共50,000条记录，包含23个字段。其中含3个分类变量（education_level含500个缺失值、city_type、current_vehicle_type）、2个二值变量（home_charging_available、previous_ev_experience）和17个连续数值变量。charging_station_accessibility与ev_knowledge_score各自存在500个空值位置。fuel_expense_per_month一列中检索到271个负值（均为-99.7），属于业务语义上的无效取值，按异常值统一标记。

三个任务的目标变量分布如表2.1所示。

表 2.1: 目标变量分布

任务	目标	类别分布	不平衡程度
任务一	ev_adoption_likelihood	High 59.3% / Medium 24.2% / Low 16.5%	严重
任务二	home_charging_available	1: 65.0% / 0: 35.0%	轻度
任务三	task3_anxiety_label	0: 50.8% / 1: 49.2%	均衡

2.2 数据清洗流水线

完整预处理流程由单一Python脚本实现，全链路可复现。步骤如下：

- 缺失指示变量：**在数值填补前，分别为education_level、charging_station_accessibility、ev_knowledge_score生成缺失指示列（各有500个标记位）。annual_income与daily_commute_km原始数据完整，为保持列结构一致，同样预置恒为0的指示变量。
- 异常值处理：**将fuel_expense_per_month中271个-99.7值置为NaN，同时生成fuel_expense_invalid标记列记录异常位置。
- 分类缺失值填充：**education_level的500个缺失位置以字符串“Missing”填充，作为独立类别参与建模。CatBoost原生支持缺失值识别，线性模型经独热编码后也等价形成独立分类，无需额外预处理。
- 数值缺失值填补：**三个存在缺失的数值列统一以中位数填补：充电站可达性填5.90，EV知识评分填7.00，燃油月支出填295.60。
- 缩尾处理：**全部17个连续变量按1%与99%分位数做双边缩尾，分位数边界以外的极端值被钳制至边界值，以控制离群点对后续线性模型参数估计的干扰。

6. **对数变换**: 对fuel_expense_per_month与annual_income分别取自然对数, 生成ln_fuel与ln_income。两个变量原始分布均呈右偏形态, 变换后分布对称性明显改善。
7. **有序编码**: edu_ord将学历按递增方向编码为1-4 (High School=1, Bachelor=2, Master=3, PhD=4), target_ord将采用意愿编码为Low=1, Medium=2, High=3。
8. **标签编码**: education_level、city_type、current_vehicle_type三列通过sklearn LabelEncoder转换为整数编码。
9. **任务三标签**: 以range_anxiety_score大于5为阈值生成二值标签 (大于5标记为1, 否则为0), 得到task3_anxiety_label列, 分布为0: 25395, 1: 24605。

2.3 最终数据规格

清洗结果保存为processed_data.xlsx, 规格为50,000行×34列, 较原始23列新增11个衍生列。数据集零缺失值、零无穷值, 分类变量全部转换为整数编码, 连续变量完成双边缩尾。三个子任务的建模均以该文件为统一数据入口。

3 子问题一: 电动汽车采用意愿分类

3.1 问题定义与难点

任务一的目标是基于消费者画像与行为特征, 预测ev_adoption_likelihood的Low、Medium、High三个等级。该任务的评分为准确率 (权重20%)。

核心难点包括: (1) **类别不均衡**——High类占比59.3%, 若全部预测为High先天准确率即达59.3%; (2) **Medium的模糊性**——作为过渡等级, 边界不清晰, 相邻等级之间的误判是三分类模型的主要误差来源; (3) **特征与目标的关系非线性**——消费者采用意愿受收入、认知、态度、经济负担、出行需求等多因素交叉影响。

3.2 探索性数据分析

3.2.1 目标变量分布

如图3.1所示, High类 (59.3%) 约为Low类 (16.5%) 的3.6倍, 存在显著类别不均衡。




图 3.1: 电动汽车采用意愿分布

3.2.2 年收入与采用意愿的关系

不同采用意愿群体的年收入分布如图3.2所示。Low、Medium、High三组的中位数年收入分别约为2.6万、3.0万和4.7万美元，表明年收入是区分三类采用意愿的强因子。但三类之间存在较大重叠区域，仅靠收入阈值无法完美分离。




图 3.2: 不同采用意愿群体的年收入分布

3.2.3 核心特征相关性分析

热力图 (图3.3) 揭示了以下关键关系: (1) `daily_commute_km`与`weekly_travel_distance_km`相关系数为0.95, 高度共线, 直接同时入模可能导致信息冗余; (2) `range_anxiety_score`与`technology_affi`

(-0.63)、ev_knowledge_score (-0.62) 呈中高度负相关；(3) environmental_awareness_score与ev_knowledge_score关系系数为0.75，表明环保意识与技术认知紧密关联。

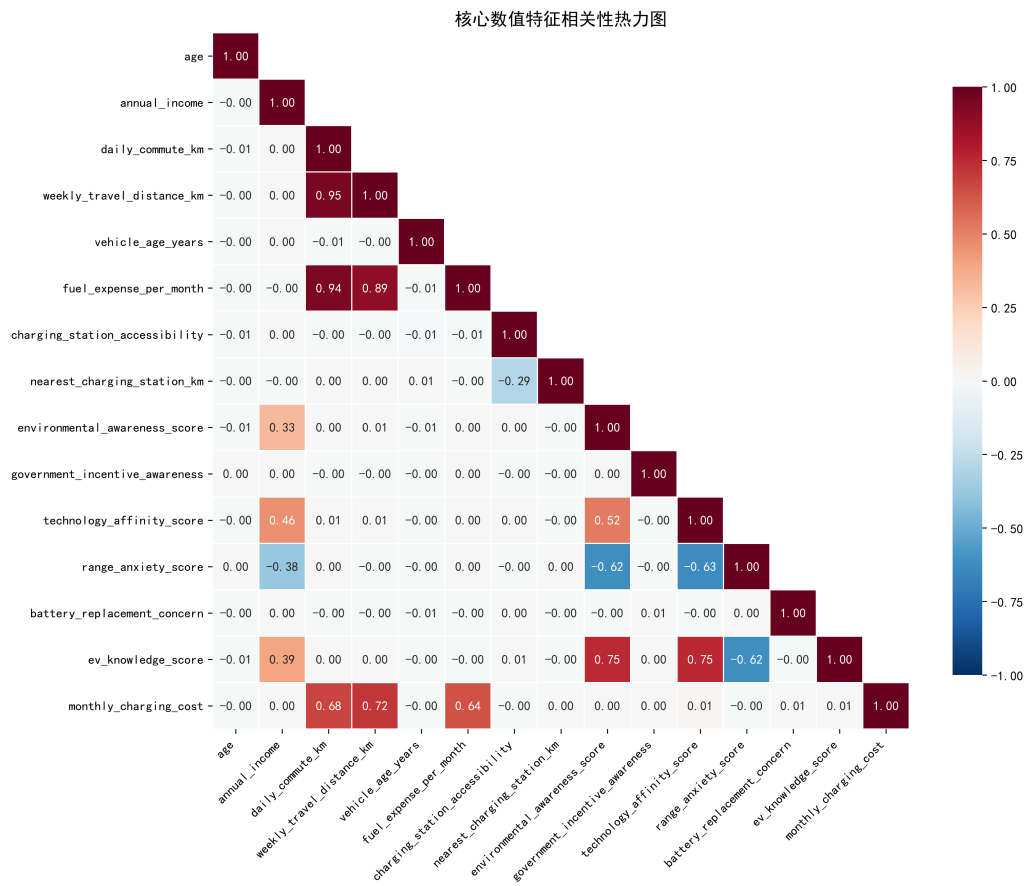


图 3.3: 核心数值特征相关性热力图

3.3 特征工程

基于相关性分析和业务理解，针对任务一构造了8个业务交互特征，如表3.1所示。

表 3.1: 任务一业务交互特征

特征名称	计算公式	业务含义
fuel_burden_ratio	$\frac{12 \cdot \text{fuel_expense}}{\text{annual_income} + \varepsilon}$	燃油负担率: 燃油成本对收入的压力
travel_consistency	$\frac{\text{weekly_km}}{7 \cdot \text{daily_km} + \varepsilon}$	出行一致性: ≈ 1 为规律通勤, >1 为不规律长途
charging_convenience	$\frac{\text{charging_access}}{\text{nearest_station} + 1}$	充电便利综合量: 纳入主观可达性与客观距离
green_tech_score	$\text{env_aware} \times \text{tech_aff}$	绿色技术倾向: 两类态度的协同放大效应
knowledge_anxiety_gap	$\text{ev_know} - \text{range_anxiety}$	认知焦虑差: EV知识能否抵消续航焦虑
ev_cost_ratio	$\frac{12 \cdot \text{charge_cost}}{\text{annual_income} + \varepsilon}$	电动使用成本率: 充电费用的经济压力
replace_tendency	$\text{veh_age} \times \text{fuel_expense}$	换车倾向近似: 车龄与油耗的交互
monthly_disp_income	$\text{annual_income}/12$	月可支配收入近似

注: $\varepsilon = 10^{-6}$ 防止除零, 所有比值特征出现NaN时填0。

3.4 训练策略与超参数

采用三阶段递进式调参策略:

1. 第一轮 (基线验证): 默认参数CatBoost + 原始特征, 验证管线正确性;
2. 第二轮 (特征消融): 对比原始特征/业务特征/类别权重方案;
3. 第三轮 (超参数搜索): 随机搜索8组参数, 5折分层CV下选择平均准确率最高的配置。

CatBoost超参数搜索范围: $\text{depth} \in [5, 9]$, $\text{learning_rate} \in [0.02, 0.1]$, $\text{iterations} \in [500, 2000]$, $\text{l2_leaf_reg} \in [3, 15]$, $\text{loss_function}=\text{MultiClass}$, $\text{eval_metric}=\text{Accuracy}$, $\text{early_stopping_round} \in [10, 100]$ 。类别权重消融测试了不加权、balanced和sqrt.balanced三种方案。

3.5 实验结果

3.5.1 验证集方案对比

在10,000条独立验证集上, 各方案的准确率对比如表3.2所示。

表 3.2: 任务一验证集方案对比

方案	ACC	Macro F1	Balanced ACC	说明
多数类基线	≈ 0.593	—	0.333	全预测为High
LR 默认权重	0.8668	0.8294	0.8265	可解释性基线
LR balanced权重	0.8575	0.8263	0.8400	加权提高少数类召回
CatBoost 默认 (raw)	0.8632	0.8251	0.8211	187轮早停
CatBoost 默认 (+业务特征)	0.8632	0.8245	0.8213	默认参数下未提升
CatBoost 调参 (+业务特征)	0.8633	0.8246	0.8213	最终模型

逻辑回归默认权重以0.8668的准确率略优于调参后CatBoost (0.8633)，说明在40维特征空间中线性模型已能较好拟合。最终模型的最优参数为：depth=5，learning_rate=0.05，iterations=1500，l2_leaf_reg=15，5折CV平均准确率为 0.8730 ± 0.0025 。

3.5.2 类别权重消融

表 3.3: 类别权重消融结果

权重方案	5折CV准确率
不加权	0.8730 ± 0.0025
balanced	0.8713 ± 0.0018
sqrt_balanced	0.8705 ± 0.0015

在竞赛以准确率为唯一指标的条件下，不加权方案最优。加权虽然提高了少数类召回，但牺牲了多数类预测准确率。

3.5.3 混淆矩阵分析

最终模型的验证集混淆矩阵如表3.4所示。

表 3.4: 任务一混淆矩阵（验证集10,000样本）

真实 \ 预测	High	Low	Medium	样本数	误判率
High	5,548	0	386	5,934	6.5%
Low	1	1,312	337	1,650	20.5%
Medium	397	246	1,773	2,416	26.6%

误判模式显示：（1）Low类误判主要流向Medium（99.7%），仅1例被误解为High——模型能很好区分Low与High之间的鸿沟；（2）Medium类误判率最高（26.6%），16.4%被过判为High——作为过渡类别，同时受两端特征拖拽；（3）High类误判率仅6.5%，零例流向Low，模型对多数类的识别非常自信。

3.5.4 特征重要性排名

CatBoost最终模型的PredictionValuesChange特征重要性Top 10如表3.5所示。本研究构造的两个业务交互特征knowledge_anxiety_gap（得分21.68）和green_tech_score（得分20.03）占据前两位，远超出下一名battery_replacement_concern（9.68）。Top 10特征中6个属于认知与态度维度，说明采用意愿主要由心理认知因素驱动，经济因素起次要作用。

表 3.5: 任务一特征重要性Top 10

排名	特征	重要性
1	knowledge_anxiety_gap ◆	21.68
2	green_tech_score ◆	20.03
3	battery_replacement_concern	9.68
4	charging_station_accessibility	9.24
5	government_incentive_awareness	7.64
6	charging_convenience ◆	5.43
7	home_charging_available	4.87
8	previous_ev_experience	3.74
9	environmental_awareness_score	2.22
10	range_anxiety_score	1.98

注：◆ 标记为本研究构造的业务交互特征。

4 子问题二：家庭充电设施安装潜力预测

4.1 问题定义与难点

任务二的目标是预测home_charging_available（二分类：0/1），即识别具备家庭充电条件的用户。该任务在评分体系中权重最高（40%），评估指标仅采用准确率。

模型从数据中学习的是当前家庭充电可用状态的标注模式。将预测为1的用户划入安装潜力较高人群，是对数据列原始语义的忠实映射，其产出可直接服务于充电设施推广决策。

标签含义界定是本任务的首要前提。赛题目标变量名称与数据描述之间存在语义差距：“当前充电可用状态”反映既有设施条件，“安装潜力”则指向未来行为。两个概念的差异划定了建模框架的基本边界。**下游变量风险**需要关注。ev_adoption_likelihood很可能是家庭充电条件的下游结果（拥有家充条件的用户因此表现出较高的采用意愿），因果方向恰与预测任务相反。用下游标签预测上游条件属于逻辑上的反向因果，主方案排除该变量。**单变量区分度极低**。EDA中，有家充与无家充群体在最近充电站距离上中位数完全一致（6.9 km），三种城市类型的家充比例差异不超过0.4个百分点（64.8%–65.2%）。原始特征对目标无区分能力。

4.2 探索性数据分析

4.2.1 目标变量分布

家充可用用户占比65.0%，类别呈轻度不平衡（图4.1）。




图 4.1: 家庭充电设施可用性分布

4.2.2 充电站距离与家充状态

如图4.2所示，有/无家庭充电的群体在最近充电站距离上的中位数完全相同（6.9 km），单变量区分为零。




图 4.2: 最近充电站距离按家充状态分组箱线图

4.2.3 城市类型与家充状态

三种城市类型的家充比例几乎完全一致（农村64.9%，郊区65.2%，城市64.8%），差异不到0.4个百分点，如图4.3所示。




图 4.3: 不同城市类型的家庭充电可用性比例

城市类型在边际分布上对家充比例几乎无区分：农村64.9%、郊区65.2%、城市64.8%。仅从比例数值判断，三类城市无差异。但这一事实不能简单理解为城市类型不相关——农村用户因公共充电设施匮乏更倾向于安装家用充电桩，城市用户可能出于环保意识与较高收入主动配备，郊区用户则受益于独立住宅提供的充裕安装空间。比例相等背后代表三种运行机制不同的驱动逻辑。同比比例异成因的格局，为构造城市类型与其他变量的交互特征提供了依据。

4.3 EDV预诊断：特征来源信号验证

在进行超参数搜索之前，首先执行探索性数据验证（Exploratory Data Validation, EDV），以判定特征来源是否包含可供模型学习的有效信号。诊断结果见表4.1。

表 4.1: 任务二EDV诊断结果

方案	验证ACC	ROC-AUC
多数类基线（全部预测为1）	0.6498	0.5000
严格特征 + Logistic Regression	0.6498	0.4955
严格特征 + ExtraTrees	0.6485	0.4973
严格特征 + HistGradientBoosting	0.6498	0.4935
严格特征 + CatBoost	0.6498	0.4947
加入真实采用意愿的诊断上界 + CatBoost	0.6694	0.6160

排除ev_adoption_likelihood等下游变量后，全部可观测特征与家充标签的Pearson相关系数绝对值均在0.013以下。四种模型（逻辑回归、随机森林、直方梯度提升、CatBoost）的ROC-AUC值全部集中在0.50附近，准确率严格等于多数类基线。一项关键对照是：

将真实采用意愿作为诊断上界加入特征集合后，准确率仅提升至0.6694，比基线高约2个百分点。该诊断信息在实际部署中无法获取，其意义在于为信号上限提供了定量参照。综合以上结果，特征来源本身缺乏有效信号是核心瓶颈，模型选择和调参策略并非限制因素。

4.4 S0/S1/S2三方案对照设计

基于EDV的诊断结论，设计了三套特征来源方案，逐层剥离瓶颈。

S0：严格原始特征版（安全基线）。仅使用city_type、充电条件、经济与教育、车辆与出行需求等可观测特征，删除ev_adoption_likelihood、target_ord、task3_anxiety_label在内的全部跨任务标签信息。S0是跨任务信息隔离的安全基线方案。

S1：真实采用意愿上界版（诊断用途）。在S0上加入真实ev_adoption_likelihood，仅用于回答一个问题：“若采用意愿在预测时已知，最多能提升多少？”S1不作为可部署方案。

S2：任务一OOF概率堆叠版（推荐主方案）。不使用真实采用意愿标签，改为两步走：首先构建删除了home_charging_available字段的Task1-no-home模型，随后用该模型输出5个堆叠特征——stack_p_low/medium/high（三类别概率）、stack_adoption_expectation（期望值）与stack_adoption_entropy（预测熵）。堆叠概率在训练集内部通过5折交叉拟合生成（每折以其中4折训练Task1-no-home、预测剩余1折），验证集侧仅由全训练集模型做一次前向预测，从机制上杜绝标签泄漏。

4.5 特征工程

任务二共构造7个业务交互特征（表4.2）。long_commute_flag与income_quantile_group的阈值分位数严格从训练集计算（fit=True），验证集则沿用训练集统计量（fit=False），杜绝信息从验证集回传至训练过程。

表 4.2: 任务二业务交互特征

特征	计算方式	业务含义
charging_scarcity	$\frac{\text{nearest_station}}{\text{charge_access} + 1}$	公共充电稀缺度
long_commute_flag	$\mathbf{1}[\text{daily_cm} > Q_{75}]$	长通勤标志
income_quantile_group	四分位数分4组	收入分位组
vehicle_renewal_need	$\text{veh_age} \times \text{fuel_expense}$	车辆更新需求
monthly_travel_intensity	$\text{weekly_km} \times 4.33$	月行驶强度近似
city_charging_interaction	$\text{city_type} \times \text{nearest_station}$	住宅环境交互（充电）
city_income_interaction	$\text{city_type} \times \text{annual_income}$	住宅环境交互（收入）

4.6 实验结果：负结果报告

4.6.1 S1诊断上界

S1方案（加入真实`ev_adoption_likelihood`）的最高准确率为0.6694，仅超出多数类基线约2个百分点。这一数值构成了一个明确的结论：即使在预测时获得真实采用意愿信息，家充预测的准确率上限也十分有限。

4.6.2 S2 OOF概率堆叠

S2方案的结果如表4.3所示。所有模型全部退化为多数类基线，ACC严格等于0.6498。

表 4.3: 任务二S2方案验证集结果

模型	ACC	ROC-AUC	说明
多数类基线	0.6498	0.5000	全预测为1
LR (无权重)	0.6498	–	退化为多数类
LR (balanced)	0.4970	–	随机猜测
CatBoost 默认	0.6498	0.491	67次迭代即早停
CatBoost CV最优	0.6498	0.489	3组参数全部同分

超参数搜索中3组候选参数在5折交叉验证下全部获得 0.64975 ± 0.00000 的准确率，折间方差严格为零。零方差结果本身构成强诊断信号：最优阈值搜索仅需处理单一类别的概率分布，OOF概率几乎不随特征变化而波动。最优OOF阈值搜索结果0.10（等价于几乎总是预测为1）。最终模型在验证集上3,502个无家充样本全部被误判为有家充，召回率等于零。

4.7 原因分析与方法论贡献

4.7.1 不可观测因素分析

家庭充电设施可用性主要由数据集中缺失的因素决定：

1. **住房属性：** 是否拥有独立住宅或私人车库、房屋类型（公寓vs别墅）、房屋产权（自有vs租赁）；
2. **物业政策：** 小区是否允许安装充电桩、是否有电力扩容条件；
3. **停车条件：** 固定车位vs公共停车位。

城市类型、收入、充电站距离等可观测变量与住房条件之间确实存在逻辑关联，然而这种关联在统计层面上过于间接，有监督学习模型无法从中提取有效信号。

4.7.2 方法论贡献

尽管预测结果不理想，整套研究流程在方法论层面提供了若干可复用的经验：

1. **EDV先行诊断框架**：在部署大规模超参数搜索之前，先通过多模型对比快速判断特征来源是否包含可学习信号，避免在无效数据上投入过度的优化资源；
2. **S0/S1/S2消融体系**：以严格特征、诊断上界、跨任务堆叠三层级对照设计，逐一排除模型选择、调参不足、特征工程缺失等可能的失败原因；
3. **跨任务无泄漏堆叠设计**：Task1-no-home模型删除home_charging_available字段后再生成OOF概率，两阶段推理链可完整复现且保证信息隔离；
4. **负结果的诚实报告**：从EDV诊断至逐层消融至最终判定的完整链路，可作为同类问题中信号验证与瓶颈定位的复用模板。

5 子问题三：里程焦虑敏感度识别

5.1 问题定义与难点

任务三聚焦于里程焦虑高敏感用户的识别。按赛题建议，将原始range_anxiety_score（1-10分）二值化：评分 >5 为高焦虑（1）， ≤ 5 为低焦虑（0）。样本量基本五五开（低焦虑50.8% vs 高焦虑49.2%）。评分权重40%。

核心难点有三层。第一层，**标签防泄漏**——标签由range_anxiety_score二值化得来，生成后必须把原始评分从特征集里删干净，留一丝都算作弊。第二层，**边界样本的模糊性**：评分恰好落在5和6的样本，特征分布高度重叠，这恰恰是模型最容易翻车的地方。第三层，**下游变量风险**——ev_adoption_likelihood很可能被里程焦虑直接左右（高焦虑 $\rightarrow$ 低采用意愿），主方案不能带这个变量。

5.2 探索性数据分析

5.2.1 目标分布与评分分布

高低焦虑分类基本均衡（图5.1a），无需特别调整类别权重。原始评分分布呈“两端少、中间多”的近似对称形态（图5.1b）。有意思的是——阈值恰好切在分布正中心。评分5和6的样本都处在群体密度最高的区间，模型没法靠“记住”某个评分段的特征模式来轻松分类，这本身就是难度所在。




图 5.1: 任务三目标分布与评分分布

5.2.2 充电困难度与EV知识按焦虑分组

图5.2给出了一条很清晰的趋势。高焦虑组的充电困难度中位数和上四分位数均显著高于低焦虑组；反过来，低焦虑组的EV知识得分中位数明显更高。对电动车技术、成本、充电方式的了解程度，看起来是降低里程焦虑的有效“缓冲”。这个东西可观测，可度量，而且是可干预的——知道得多，焦虑就少。




图 5.2: 充电困难度与EV知识得分按焦虑标签分组箱线图

5.2.3 核心特征相关性

从热力图（图5.3）中，我们注意到几条几乎同样强的信号：range_anxiety_score与battery_replacement_cost呈正相关（+0.63），与technology_affinity_score（-0.63）和ev_knowledge_score（-0.62）呈负相关。里程焦虑主要由认知/态度维度驱动。相比之下，硬件条件（家充、充电站距离）的单变量区分度低得多——home_charging_available与焦虑标签的相关系数仅为-0.012。

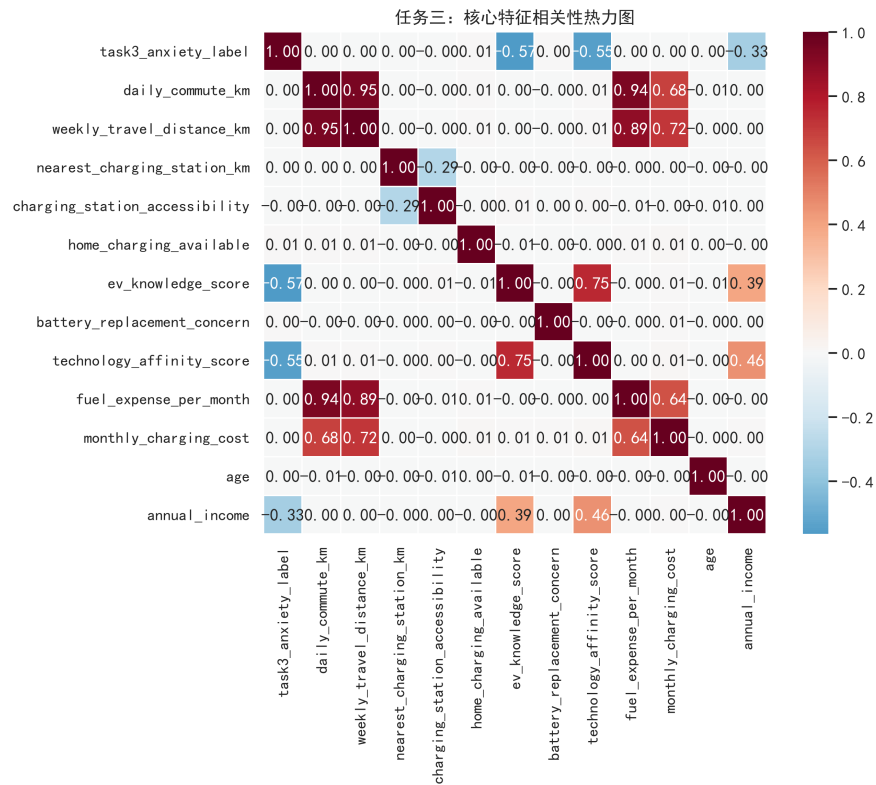


图 5.3: 任务三核心特征相关性热力图

5.3 特征工程

基于上述”认知主导，硬件加成交互”的模式发现，我们为任务三构造了7个业务交互特征（表5.1）。high_mileage_low_convenience依赖训练集分位数阈值，通过fit=True/False接口管理。

表 5.1: 任务三业务交互特征

特征	计算公式	业务含义
extra_travel_intensity	$\text{weekly_km} - 5 \cdot \text{daily_km}$	额外出行强度
daily_travel_approx	$\text{weekly_km} / 7$	日均出行近似
charging_difficulty	$\frac{\text{nearest_station}}{\text{charge_access} + 1}$	充电困难度
knowledge_buffer	$\text{ev_know} - \text{battery_concern}$	知识缓冲量
high_mileage_low_convenience	$\mathbf{1}[\text{weekly_km} > Q_{75}] \wedge \mathbf{1}[\text{access} < Q_{25}]$	高里程低便利标志
home_charging_buffer	$\text{home_charging} \times \text{daily_km}$	家充缓冲交互
long_distance_ratio	$\frac{\text{weekly_km}}{7 \cdot \text{daily_km} + \varepsilon}$	长途占比

5.4 Main与Ablation消融设计

Main方案（主方案）：排除ev_adoption_likelihood，仅使用可观测特征。采用三阶段递进式调参，超参数搜索范围：depth $\in [4,8]$ ，learning_rate $\in [0.02,0.1]$ ，iterations $\in [500,1800]$ ，l2_leaf_reg $\in [3,15]$ ，random_strength $\in [0,2]$ 。loss_function=Logloss，eval_metric=Logloss。Main方案共搜索8组参数（40次CV训练）。

Ablation方案（消融对照）：加入ev_adoption_likelihood作为分类特征，纯粹用来衡量“若采用意愿已知，焦虑识别能提升多少”。Ablation方案搜索3组参数（15次CV训练）。消融结果仅作参考，不作为可部署方案——采用意愿很可能是焦虑的下游结果，真实预测流程中根本拿不到这个变量。

5.5 实验结果

5.5.1 交叉验证阶段

Main方案8组参数的5折CV结果如表5.2所示。所有参数组的OOF阈值准确率高度集中（0.86018 – 0.86077，极差仅0.00059），折间标准差在0.0014 – 0.0024之间。最佳参数为：depth=8，learning_rate=0.02，iterations=354，l2_leaf_reg=10.0，random_strength=0.5，OOF阈值准确率=0.86077，OOF AUC=0.90676。

表 5.2: 任务三 Main方案 CV阶段结果

Trial	depth	lr	iter	l2	rs	CV ACC	OOF AUC
1	8	0.02	500	10.0	0.5	0.86052	0.90676
2	6	0.02	800	10.0	0.5	0.86025	0.90659
3	8	0.07	1500	15.0	1.5	0.86025	0.90589
4	4	0.10	1500	3.0	0.5	0.85992	0.90684
5	4	0.10	1500	15.0	0.5	0.86018	0.90645
6	7	0.07	1500	3.0	1.0	0.85965	0.90630
7	7	0.10	1500	7.0	1.0	0.85967	0.90575
8	5	0.02	800	3.0	0.5	0.86050	0.90643

一个让人相当放心的现象：所有参数组性能高度集中。这意味着里程焦虑的特征信号确实够强——不同合理参数均能收敛到几乎相同的预测能力。跟任务二中所有参数全部同分的“零信号”模式相比，完全是两个世界。

5.5.2 验证集方案对比

在10,000条独立验证集上，各方案的准确率对比如表5.3所示。

表 5.3: 任务三验证集方案对比

方案	ACC	AUC	Macro F1	Balanced ACC	说明
多数类基线	0.5079	0.5000	—	0.5000	全预测为0
LR (无权重)	0.8311	—	0.8306	0.8304	可解释性基线
CatBoost 默认 (+业务特征)	0.8545	0.9045	0.8541	0.8539	127轮早停
Main 调参 (最终)	0.8550	0.9042	0.8546	0.8544	可部署方案
Ablation 调参	0.8563	0.9145	0.8559	0.8557	仅作参考

Main方案调参后ACC (0.8550) 较CatBoost默认 (0.8545) 仅提升0.05个百分点, 这和CV阶段”所有参数性能高度集中”的发现是一致的。Ablation方案加入ev_adoption_likelihood后ACC较Main提升0.13个百分点, AUC提升约0.010。

5.5.3 Main vs Ablation 因果分析

Ablation虽然在本地实验中跑出了更高的准确率, 但这里有个方向性问题。根据赛题的因果关系: 高里程焦虑→低采用意愿——焦虑是原因, 采用意愿是结果。如果把采用意愿作为输入特征塞进模型, 就等于用”结果”来预测”原因”。这是在制造因果倒置。所以我们最终部署选择Main方案 (不含ev_adoption_likelihood), 消融差异如实在论文中报告。

5.5.4 混淆矩阵

Main调参模型的验证集混淆矩阵如表5.4所示。一个值得注意的不对称: 高焦虑类误判率 (18.2%) 大约是低焦虑类 (10.9%) 的1.7倍——高焦虑群体的特征分布更分散, 模型更难抓牢。

表 5.4: 任务三 Main调参模型混淆矩阵 (验证集10,000样本)

真实 \ 预测	0 (低焦虑)	1 (高焦虑)	样本数	误判率
0 (低焦虑)	4,525	554	5,079	10.9%
1 (高焦虑)	896	4,025	4,921	18.2%

5.5.5 特征重要性排名

Main调参模型特征重要性Top 15如表5.5所示。environmental_awareness_score (53.53) 和technology_affinity_score (31.36) 两个变量就占了约85%的特征重要性——也就是说, 两个变量几乎框定了里程焦虑的全部可预测差异。业务交互特征long_distance_ratio (第7)、knowledge_buffer (第12)、charging_difficulty (第14) 均挤入了Top 15的中后段。经济/人口变量的重要性远低于认知变量。里程焦虑说到底还是心理/认知现象, 特征排名把这一点写得明明白白。

表 5.5: 任务三 Main调参模型特征重要性Top 15

排名	特征	重要性
1	environmental_awareness_score	53.53
2	technology_affinity_score	31.36
3	annual_income	1.43
4	ln_income	1.39
5	ev_knowledge_score	1.01
6	government_incentive_awareness	0.94
7	long_distance_ratio ◆	0.70
8	nearest_charging_station_km	0.63
9	age	0.63
10	vehicle_age_years	0.60
11	charging_station_accessibility	0.59
12	knowledge_buffer ◆	0.57
13	battery_replacement_concern	0.54
14	charging_difficulty ◆	0.53
15	electricity_cost_per_kwh	0.47

注：◆ 标记为本研究构造的业务交互特征。

5.5.6 边界样本分析

边界样本分析是本文的一个独到视角。利用原始评分（仅作模型评估后使用，不参与训练）统计各评分段的准确率，结果如表5.6所示。

表 5.6: 任务三边界样本分析（原始评分逐段准确率）

原始评分	样本数	准确率	错误率
2	802	0.9925	0.0075
3	1,320	0.9955	0.0045
4	1,916	0.8638	0.1362
5	1,751	0.6225	0.3775
6	1,506	0.6700	0.3300
7	969	0.9969	0.0031
8	941	0.9979	0.0021
9	508	0.9980	0.0020
10	287	1.0000	0.0000

评分距阈值越远，准确率越高——一条清晰的V形错误曲线，谷底恰好扎在评分5（37.75%错误率）和6（33.00%错误率）。这条曲线有三层含义：

1. 模型学到了真正的信号。极端评分近乎完美的准确率排除了”模型在随机猜测”的嫌疑。如果模型没有真正学会焦虑预测的特征模式，所有评分段准确率应该逼近基线（≈51%），而不是呈现这样有规律的V形曲线。

2. **边界样本的固有模糊性**。评分5和6的样本占了验证集的32.6%。对于这些样本，二分标签天然带有问卷评分的主观噪声——一个评分5.0的用户和一个5.1的用户，真实焦虑程度可能毫无差别，标签却恰好被切在了两边。模型的边界混淆反映的是标签二值化在阈值处的不连续性，不是模型能力不足。
3. **与任务一的对比**。任务一Low/Medium/High之间的误判也呈现对称模式，但任务三的V形曲线尖锐得多——只需跨过约1个评分单位的距离（评分5→7），准确率就从62%飙升至99.7%。这暗示range_anxiety_score与可用特征之间的关系在群体层面高度连续且可学。

5.6 跨任务特征比较

任务一中使用了range_anxiety_score构造knowledge_anxiety_gap特征（排名第1，得分21.68）。任务三禁止触碰range_anxiety_score，我们构造了knowledge_buffer（ev_knowledge_score减去battery_replacement_concern）作为替代。两者在结构上类似但经验证无泄漏：battery_replacement_concern与knowledge_buffer的关系系数为0.63（中度相关，非函数关系， $R^2 = 0.40$ ），仍有约60%的方差独立。这个替代是干净可用的。

6 综合讨论

6.1 三任务横向对比

三项任务共享同一数据集、同一预处理流水线与同一CatBoost主模型，但预测难度呈现出三种截然不同的格局。特征信号在不同预测目标上的异质性分布构成这一差异的根源。表6.1汇总了关键指标。

表 6.1: 三项任务综合对比

维度	任务一	任务二	任务三	说明
预测类型	三分类	二分类	二分类	
验证集ACC	0.8633	0.6498	0.8550	
超过多数类基线	+27.0pp	+0pp	+34.7pp	信号强度对比
ROC-AUC	—	≈0.50	0.9042	排序能力对比
CV折间方差	0.0025	0.0000	0.0014–0.0026	信号稳定性
特征信号强弱	强	无	强	

任务一与任务三的特征信号较强，CatBoost在交叉验证和独立验证集上均稳定超越多数类基线。任务三同时达到较高的AUC（0.9042）和ACC（0.8550），边界分析中出现的V形错误曲线为这一表现提供了诊断性确认——模型受真实信号驱动，而非噪声拟合。任务二呈现完全不同的图景：四种候选模型的ROC-AUC全部在0.50附近，交叉验证折间方差严格为零。在现有特征集合范围内，家庭充电安装与否无法被有效预测。

6.2 CatBoost统一技术栈的优势

三项任务均采用CatBoost作为主模型，这一选择服务于以下四个方面的考虑。

1. **方法学一致性**：统一主模型使跨任务比较不受模型选型差异的干扰，保证了论文分析逻辑的内在连贯。
2. **实现效率**：分类特征直接在CatBoost内部声明，避免独热编码带来的维度膨胀；三项任务共享common.py、features.py等公共模块，代码复用程度较高。
3. **诊断价值**：相同模型能力上限意味着跨任务表现差异只能归因于特征来源的不同——“模型选择不当”这一替代解释得以排除。
4. **可解释性**：CatBoost内置的PredictionValuesChange特征重要性度量和SHAP值为全部三个任务提供了统一的解释框架，便于论文中并行展开分析。

6.3 特征工程策略反思

三项任务中构造了大量业务交互特征，其效果因任务信号基础不同而两极分化。

- **任务一**：knowledge_anxiety_gap与green_tech_score两个业务交互特征占据特征重要性前两位（合计41.7分），表明认知维度上的交互构造具备较强的分类能力。
- **任务二**：充电稀缺度、城市交互项等业务特征对预测近乎无贡献。底层单变量与目标间的相关性已接近零，业务特征因此失去了构造基础。
- **任务三**：long_distance_ratio、knowledge_buffer等业务特征出现在Top 15中，但位次居于中后段。CatBoost的对称树结构已在一定程度上内化了这些交互效应，业务特征在此场景下的作用更偏向显式化已知交互关系。

三项任务的横向对照指向一个共有的约束条件：特征工程的收益上限受制于底层信号的存在性。原始特征与目标无关时（任务二），任何交互构造均难以产生区分力。而原始特征信号足够时（任务三），CatBoost自身的树结构已可有效捕捉非线性交互，业务特征提供的是边际增益。

6.4 任务二负结果的学术价值

任务二是三项任务中唯一未能突破基线的子问题，但该负结果本身具备不可忽视的方法论价值。相当数量的数据科学竞赛报告倾向于仅呈现成功案例；本文选择完整记录从EDV预诊断、三方案消融到最终判定的全流程，目的如下：

1. 展示特征来源信号不足时的诊断与排除流程——先通过多模型比照确认信号是否真实存在，再决定是否投入超参数搜索，避免因果倒置。
2. 区分“模型选择不合理”与“数据本身缺乏信息”两种性质截然不同的困境，证明系统方法论可以对二者作出可靠区分。
3. 为后续研究提供一份可复用的特征有效性预诊断模板：EDV先行，调参在后。

7 结论与展望

7.1 主要发现

1. **任务一（采用意愿分类）**：CatBoost调参方案验证集ACC=0.8633，5折CV ACC=0.8730±0.002。认知与态度维度构成采用意愿的核心驱动力——knowledge_anxiety_gap与green_tech_score两个业务交互特征合计贡献41.7%的重要性，超过所有单一原始特征。类别权重消融结果确认，在准确率唯一评估指标下，不加权方案表现最优。Medium类（误判率26.6%）是三类中区分难度最高的过渡类别，推测其原因在于该类别在特征空间上位于High与Low之间的模糊地带。

2. **任务二（家充潜力预测）**：严格排除下游变量后，所有模型均退化为多数类基线（ACC=0.6498）。EDV诊断指向同一根源：住房类型、物业政策、停车条件等对家庭充电条件具决定性影响的变量均未纳入数据集，可观测特征与目标变量的单变量相关系数全部在0.013以下。S1诊断上界（加入真实采用意愿后ACC=0.6694，仅优于基线2.0个百分点）进一步印证，在现有特征集合的约束下，该问题的预测上限极为有限。对负结果的完整记录为相关研究提供了一个可参照的方法论诊断流程。

3. **任务三（里程焦虑识别）**：Main方案（不含ev_adoption_likelihood）验证集ACC=0.8550，AUC=0.9042。全部CV参数组性能高度集中（极差0.00059），信号稳定性明确。边界样本分析是本任务中最具诊断价值的环节——极端评分样本近乎完美的分类准确率表明模型捕获了真实信号；边界样本（评分5/6）的较高误判率反映的是标签二值化在阈值邻域内的固有不确定性，而非模型能力的上限。特征重要性分析中，environmental_awareness_score与tecd占据85%重要性，认知维度对里程焦虑的预测贡献远超其他变量。

7.2 方法学贡献

以下几项设计在方法层面具备跨问题的参考意义：

1. **统一CatBoost建模框架**：三项任务在模型选型、评估流程（80/20分层划分 + 5折CV + 独立验证集一次性评估）、数据预处理（共享processed_data.xlsx）上保持完全一致，为横向比较提供了干净的实验基线和连贯的论文逻辑。
2. **EDV先行诊断方法**：在投入大规模调参之前，通过多模型对照快速检验特征来源是否携带有效信号。任务二的实践表明，这一流程可以有效避免对低信号数据的无效计算。
3. **跨任务无泄漏堆叠设计**：S2方案的Task1-no-home模型配合5折OOF概率生成流程，为跨任务特征工程提供了一种严格无泄漏的实现范式。
4. **消融实验与因果推理的组合作用**：任务三的Main与Ablation对比揭示了一项重要区别——Ablation的统计指标在本地表现更好，但其因果方向决定它不适合生产部署。这一设计思路对存在因果依赖链的多变量预测问题具有潜在的参考价值。

7.3 局限性

- 超参数搜索规模有限：**三项任务的随机搜索均仅覆盖8组参数组合。后续研究可考虑采用Optuna贝叶斯优化或NNI等自动化调参框架，在更大范围内逼近更优参数配置。
- 任务一LR反超CatBoost：**逻辑回归默认权重（ACC=0.8668）略优于调参后的CatBoost（ACC=0.8633）。这一结果有两种可能解释：CatBoost超参数空间尚未被充分遍历，或在当前40维特征空间中，非线性增益已接近上限。
- 深度学习模型未覆盖：**基于Transformer的表格数据模型（TabTransformer、FT-Transformer）未在本实验中测试。自注意力机制在特定条件下可能捕捉CatBoost遗漏的高阶特征交互，该可能性有待进一步验证。
- 任务二关键特征缺失：**数据集中不包含住房类型、物业政策等对家庭充电条件具决定性影响的变量。若后续能够补充这些字段，任务二的建模结果存在重新评估的空间。
- 阈值搜索的边界条件：**任务三类别分布较为均衡，OOF阈值优化在本实验中未见实质提升（最优阈值0.45相较默认0.50，ACC差异不足0.0005）。该步骤作为分析流程的一部分予以保留，以维护论文方法论框架的完整性。

参考文献

- [1] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. Catboost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems*, 2018.
- [2] DeepSeek. Deepseek-v4-pro, v4, 2026. 使用日期: 2026-07-29.
- [3] Moonshot AI. Kimi k2.6, v2.6, 2026. 使用日期: 2026-07-29 – 2026-07-30.

AI工具使用声明

本参赛队在研究过程中使用了以下人工智能工具作为辅助手段。所有AI生成的内容均经作者严格核对、修改和验证，其正确性、可靠性及学术规范性由本参赛队承担全部责任。核心建模、算法设计、代码实现、结果分析与结论由队员独立完成。

具体使用情况如下：

- **DeepSeek-V4-Pro (v4, DeepSeek)：**用于数据清洗流水线设计和实现、任务一探索性数据分析（EDA）可视化脚本生成、任务一特征工程与完整训练流水线代码编写，以及任务一解决方案文档撰写。使用日期：2026年7月29日。

- **Kimi K2.6 (v2.6, Moonshot AI)**：用于任务二和二的代码框架搭建、EDA可视化脚本生成、特征工程实现、完整训练流水线编写、方案文档撰写，以及部分论文草稿的辅助生成。使用日期：2026年7月29日至7月30日。
- **Opencode (DeepSeek-V4-Pro, v4)**：作为交互式 CLI 编程辅助工具，在代码生成与论文撰写环节提供辅助。仅作辅助作用，所有AI生成的内容均经作者严格核对、修改和验证，其正确性、可靠性及学术规范性由本参赛队承担全部责任。核心建模、算法设计、代码实现、结果分析与结论由队员独立完成。使用日期：2026年7月29日至7月31日。

各章节中凡由AI辅助生成并修改后采用的内容，均已在对应位置以脚注标注（注明工具名称、提示词原文、生成日期及用途）。

本参赛队保证：全文AIGC生成比例不超过30%，论文整体相似比不超过50%。支撑材料中附有《AI工具使用详情说明》（文件名：BDATA2600409_AI使用说明.pdf），包含工具基本信息、使用目的、关键交互记录及采纳修改说明。

A 源代码文件清单

本研究所使用的源代码文件如下（完整代码见支撑材料）：

文件	功能说明
src/common.py	公共模块：数据加载、分层划分（seed=2026）、评估指标计算、结果保存
src/features.py	特征工程模块：三个任务的19个业务特征函数
src/train_task1.py	任务一完整训练流水线（LR基线 → CatBoost → CV调参 → 最终评估）
src/train_task2.py	任务二S0/S1/S2三方案流水线 + OOF阈值搜索
src/train_task3.py	任务三Main/Ablation消融流水线 + 边界样本分析
src/eda_task1.py	任务一EDA可视化（3张图）
src/eda_task2.py	任务二EDA可视化（3张图）
src/eda_task3.py	任务三EDA可视化（4张图）
run_training.ps1	台式机一键训练脚本（GPU/CPU自动切换）

B 运行环境

项目	配置
Python版本	3.12.2
包管理器	uv
核心依赖	catboost, scikit-learn, pandas, numpy, openpyxl, matplotlib, seaborn
GPU环境	NVIDIA GeForce RTX 3090 Ti (24 GB)
操作系统	Windows 11
随机种子	2026

C 开源代码仓库

本项目全部代码、模型文件及论文 LaTeX 源码均在 GitHub 平台开源:

- 仓库地址: <https://github.com/blackwhitetony/innoCupTaskB>
- 主要目录: src/ (训练脚本)、models/ (训练好的 .cbm 模型文件)、outputs/ (预测结果与 EDA 图片)、paper/ (论文 LaTeX 源码)
- 许可证: MIT License

D 模型调用方式

支撑材料解压后, 在项目根目录执行:

```
uv sync # 安装依赖
uv run python predict.py # 三个任务全部预测
```

也可在代码中按任务逐一调用:

```
from predict import predict_task1, predict_task2, predict_task3
from common import load_processed_data

df = load_processed_data()
pred, proba = predict_task1(df) # 任务一: 三分类
pred, proba = predict_task2(df) # 任务二: 二分类
pred, proba = predict_task3(df) # 任务三: 二分类
```

‘predict.py’ 自动处理特征工程、目标列删除与模型加载, 输入为 ‘processed_data.xlsx’ 加载后的 DataFrame, 输出为预测标签和概率。